Projeto de Experimentos Estatísticos com Imagens Sísmicas

Segmentação de Rochas Salinas e Enriquecimento Sintético de Dados (IEEE Access)

6 de novembro de 2026

1 Especificação e Delineamento dos Dados

O banco de dados sísmico original é composto por 4.000 imagens reais, divididas em:

- **2.400 imagens reais com ocorrência de sal**:
  - 1.200 imagens alocadas no conjunto de treinamento real ($D_{\text{real_train}}$);
  - 800 imagens reservadas exclusivamente para o conjunto de teste real (D_{test});
  - 400 imagens mantidas para validação/ajuste de hiperparâmetros.
- **1.600 imagens reais sem ocorrência de sal**.
- **1.200 imagens sintéticas** geradas por simulação com ocorrência de corpos de sal (D_{synth}).

Duas arquiteturas de rede neural de segmentação são comparadas:

1. $\mathcal{M}_{\text{base}}$: Rede treinada estritamente com a base real (1.200 imagens com sal);
2. $\mathcal{M}_{\text{aug}}$: Rede treinada com a base enriquecida (1.200 reais + 1.200 sintéticas com sal).

2 Métricas de Avaliação

2.1 Medida de Segmentação: Intersection over Union (IoU)

A acurácia de sobreposição espacial é quantificada pelo índice de Jaccard (IoU), estritamente no intervalo $[0, 1]$:

$$\text{IoU}(Y, \hat{Y}) = \frac{|Y \cap \hat{Y}|}{|Y \cup \hat{Y}|} \tag{1}$$

onde Y representa a máscara de referência (*ground truth*) e $\hat{Y}$ a predição binária gerada pela rede.

No caso particular em que ambos são nulos ($|Y| = 0$ e $|\hat{Y}| = 0$), define-se IoU = 1,0. Se a rede prediz falsos corpos de sal quando não há presença ($|Y| = 0$ e $|\hat{Y}| > 0$), IoU = 0,0.

2.2 Medida de Viés de Segmentação: Erro Relativo de Área (ΔArea)

Para avaliar se o modelo superestima ou subestima a extensão volumétrica/superficial das rochas salinas, define-se o desvio relativo de área:

$$\Delta\text{Area} = \frac{\text{Área}(\hat{Y}) - \text{Área}(Y)}{\text{Área}(Y)} \tag{2}$$

- $\Delta\text{Area} > 0$: superestimação sistemática da extensão do sal;
- $\Delta\text{Area} < 0$: subestimação sistemática da extensão do sal;
- $\Delta\text{Area} = 0$: calibração dimensional ideal.

3 Teste A: Teste Pareado de Desempenho na Segmentação do Banco Aumentado (Wilcoxon Signed-Rank Test)

3.1 Objetivo e Configuração

Avaliar se a rede treinada com o banco aumentado ($\mathcal{M}_{\text{aug}}$) apresenta acurácia estatisticamente superior à rede base ($\mathcal{M}_{\text{base}}$) quando avaliada exatamente sobre as mesmas 800 imagens do conjunto de teste real (D_{test}).

Para cada imagem $i \in \{1, \ldots, 800\}$, calcula-se a diferença pareada:

$$d_i = \text{IoU}(\mathcal{M}_{\text{aug}}(x_i), y_i) - \text{IoU}(\mathcal{M}_{\text{base}}(x_i), y_i) \tag{3}$$

3.2 Hipóteses Estatísticas (Unilateral)

- H_0 : Mediana$(d) \leq 0$ (O enriquecimento com sintéticas não melhora o IoU na base real de teste).
- H_1 : Mediana$(d) > 0$ (O enriquecimento melhora significativamente o IoU na base real de teste).

3.3 Tamanho de Efeito

O tamanho de efeito para o teste pareado de postos sinalizados de Wilcoxon é reportado via correlação bisserial por postos (*matched-pairs rank-biserial correlation*):

$$r = \frac{W^+ - W^-}{W^+ + W^-} \tag{4}$$

onde W^+ e W^- são a soma das ordens dos postos com diferenças positivas e negativas, respectivamente.

3.4 Validação Estatística das Premissas (Checklist Metodológico)

Antes de validar o resultado de Wilcoxon, deve-se verificar os seguintes pressupostos:

1. **Dependência Pareada e Independência entre Pares**: Cada par de medidas $(x_i^{\text{aug}}, x_i^{\text{base}})$ é obtido sobre a exata mesma imagem sísmica real i. As imagens de teste foram amostradas de forma independente, garantindo que os pares sejam mutuamente independentes.
2. **Nível de Mensuração Contínuo/Ordinal**: O índice de Jaccard (IoU) é uma variável contínua no intervalo $[0, 1]$, satisfazendo a exigência de escala estritamente ordinal/contínua.
3. **Verificação de Não-Normalidade das Diferenças**: Aplica-se o teste de Shapiro-Wilk sobre as diferenças d_i:

$$W_{\text{shapiro}} = \frac{\left(\sum a_i d_{(i)}\right)^2}{\sum (d_i - \bar{d})^2} \tag{5}$$

Caso $p_{\text{shapiro}} < 0{,}05$, rejeita-se a normalidade, justificando formalmente a inadequação do teste t de Student pareado e a necessidade do teste não-paramétrico de Wilcoxon.

4. **Simetria da Distribuição das Diferenças**: Para que o teste de Wilcoxon seja interpretado como teste de *mediana* (e não apenas de postos médios), a distribuição das diferenças d_i deve ser aproximadamente simétrica em torno da mediana. Avalia-se o coeficiente de assimetria de Fisher-Pearson (*skewness*) e a inspeção visual de histograma/KDE de d_i.

3.5 Como Avaliar e Interpretar o Resultado do Teste A

A interpretação dos resultados pelo revisor do IEEE Access exige uma análise conjunta em três níveis:

1. **Decisão de Significância Estatística** ($\alpha = 0{,}05$):
   - Se $p < 0{,}05$: Rejeita-se H_0. Há evidência estatística de que o modelo enriquecido com sintéticas ($\mathcal{M}_{\text{aug}}$) gera desempenho superior ao modelo base ($\mathcal{M}_{\text{base}}$) em imagens reais não vistas.
   - Se $p \geq 0{,}05$: Não se rejeita H_0. Conclui-se que o acréscimo de sintéticas não proporcionou ganho detectável de segmentação.
2. **Magnitude e Relevância Prática (Tamanho de Efeito r)**: De acordo com os critérios convencionais de Cohen/Kerby para correlação bisserial:
   - $|r| < 0{,}10$: Efeito nulo ou desprezível;
   - $0{,}10 \leq |r| < 0{,}30$: Efeito pequeno (ganho modesto);
   - $0{,}30 \leq |r| < 0{,}50$: Efeito moderado (ganho consistente e perceptível nas inferências sísmicas);
   - $|r| \geq 0{,}50$: Efeito grande (impacto substancial do aumento sintético).
3. **Impacto Clínico/Operacional nas Métricas**: Avalia-se a mediana da diferença (Mediana(d)) e a taxa de pares favoráveis (% de imagens em que $\text{IoU}_{\text{aug}} > \text{IoU}_{\text{base}}$). Se Mediana($d$) > 0 com ganho de, por exemplo, +3 a +8 pontos percentuais em IoU, confirma-se o sucesso operacional do treinamento sintético.

4 Teste B: Análise de Viés Sistemático : Sobre-segmentação/Sub-segmentação (Mann-Whitney U / Wilcoxon Rank-Sum)

4.1 Objetivo e Configuração

Verificar se a rede enriquecida ($\mathcal{M}_{\text{aug}}$) apresenta distorção ou assimetria dimensional quando aplicada a imagens sintéticas em relação às imagens reais. Avalia-se se as predições tendem a superestimar ou subestimar sistematicamente o tamanho dos objetos segmentados entre os dois domínios:

- Grupo 1 ($n = 800$): Erros relativos de área na base de teste real, $\Delta\text{Area}_{\text{real}}$;
- Grupo 2 ($m = 1.200$): Erros relativos de área na base sintética, $\Delta\text{Area}_{\text{synth}}$.

4.2 Hipóteses Estatísticas (Bilateral)

- H_0: A distribuição de $\Delta\text{Area}_{\text{synth}}$ é equivalente à de $\Delta\text{Area}_{\text{real}}$ ($P(\Delta\text{Area}_{\text{synth}} > \Delta\text{Area}_{\text{real}}) = 0{,}5$).
- H_1: As distribuições diferem estocasticamente, indicando tendência sistemática de superestimação ou subestimação relativa entre imagens reais e sintéticas.

4.3 Tamanho de Efeito

O tamanho de efeito é mensurado por:

$$\text{CLES} = \frac{U}{n \cdot m}, \qquad r = 1 - \frac{2U}{n \cdot m} \tag{6}$$

onde CLES (*Common Language Effect Size*) representa a probabilidade de superioridade empírica.

4.4 Validação Estatística das Premissas (Checklist Metodológico)

Para fundamentar o teste de Mann-Whitney U:

1. **Independência entre os Grupos**: As 800 imagens de teste reais e as 1.200 imagens sintéticas constituem amostras completamente independentes (geradores distintos e sem compartilhamento amostral).
2. **Continuidade e Ordinalidade da Métrica de Viés**: ΔArea varia em escala contínua (excluindo-se ou tratando separadamente imagens sem sal no ground-truth).
3. **Homogeneidade das Formas de Distribuição**:
   - Se os dois grupos apresentarem densidades empíricas com formatos similares (verificados por teste de Levene para homogeneidade de variâncias de postos ou inspeção gráfica via curvas KDE), o teste de Mann-Whitney testa rigorosamente a **diferença entre medianas**.
   - Se os formatos forem heterogêneos, o teste avalia a **dominância estocástica** ($P(X > Y) \neq 0{,}5$).

4.5 Como Avaliar e Interpretar o Resultado do Teste B

A interpretação estatística e geofísica deve ser conduzida conforme os seguintes desfechos:

1. **Ausência de Viés Sistemático Diferencial ($p \geq 0{,}05$)**:
   - Não se rejeita H_0. Indica que o comportamento preditivo da rede neural em relação à escala dos corpos salinos é estatisticamente idêntico em imagens reais e sintéticas. Isso valida a fidelidade morfológica das imagens geradas pelo simulador.
2. **Presença de Viés Sistemático Diferencial ($p < 0{,}05$)**:
   - Rejeita-se H_0. Há distorção sistemática de área entre os domínios. A direção da tendência é revelada pela comparação das medianas e pelo sinal de r:
     - Se $\text{Mediana}(\Delta\text{Area}_{\text{synth}}) > \text{Mediana}(\Delta\text{Area}_{\text{real}})$ (e $r < 0$ / CLES $> 0{,}5$): A rede tende a **superestimar** (sobre-segmentar) os corpos de sal sintéticos quando comparados aos reais.
     - Se $\text{Mediana}(\Delta\text{Area}_{\text{synth}}) < \text{Mediana}(\Delta\text{Area}_{\text{real}})$: A rede tende a **subestimar** (sub-segmentar) nas sintéticas, indicando que o simulador gera feições de sal que a rede detecta com maior conservadorismo de bordas.
3. **Critério de Tolerância Geofísica**: Mesmo com $p < 0{,}05$, caso a diferença entre as medianas seja dimensionalmente desprezível (ex: $|\text{Mediana}_{\text{synth}} - \text{Mediana}_{\text{real}}| < 2\%$) e o tamanho de efeito for insignificante ($|r| < 0{,}10$), reporta-se que o desvio estatístico reflete o grande poder amostral ($n + m = 2.000$) e não um viés com relevância prática.

5 Implementação em Python

O código a seguir automatiza os cálculos das métricas, execuções dos testes não-paramétricos e geração dos estimadores de tamanho de efeito:

```python
import numpy as np
from scipy import stats

def compute_iou(mask_true, mask_pred):
    """Calcula o IoU no range [0, 1]."""
    intersection = np.logical_and(mask_true, mask_pred).sum()
    union = np.logical_or(mask_true, mask_pred).sum()
    if union == 0:
        return 1.0  # Sem sal no ground truth e predito sem sal
    return float(intersection) / float(union)

def compute_area_bias(mask_true, mask_pred):
    """
    Mede o erro relativo de area:
    > 0: superestimacao, < 0: subestimacao.
    """
    area_true = mask_true.sum()
    area_pred = mask_pred.sum()
    if area_true == 0:
        return np.nan
    return float(area_pred - area_true) / float(area_true)

# ============================================================================
# TESTE A: Wilcoxon Signed-Rank Test (Pareado, n=800)
# ============================================================================
def run_experiment_a(iou_base, iou_aug):
    """
    iou_base: IoU da rede treinada so com reais (800 imagens)
    iou_aug:  IoU da rede treinada com enriquecimento (800 imagens)
    """
    iou_base = np.asarray(iou_base)
    iou_aug = np.asarray(iou_aug)
    diff = iou_aug - iou_base

    # Wilcoxon unilateral: H1 e iou_aug > iou_base
    stat, p_val = stats.wilcoxon(iou_aug, iou_base, alternative='greater')

    median_base = np.median(iou_base)
    iqr_base = stats.iqr(iou_base)
    median_aug = np.median(iou_aug)
    iqr_aug = stats.iqr(iou_aug)
    median_diff = np.median(diff)

    # Rank-biserial correlation
    non_zero = diff[diff != 0]
    ranks = stats.rankdata(np.abs(non_zero))
    w_pos = np.sum(ranks[non_zero > 0])
    w_neg = np.sum(ranks[non_zero < 0])
    r_rb = (w_pos - w_neg) / (w_pos + w_neg) if (w_pos + w_neg) > 0 else 0.0

    print("=== TESTE A (Wilcoxon Pareado) ===")
    print(f"Mediana IoU Base: {median_base:.4f} (IQR: {iqr_base:.4f})")
    print(f"Mediana IoU Enriquecida: {median_aug:.4f} (IQR: {iqr_aug:.4f})")
    print(f"Mediana da Diferenca: {median_diff:+.4f}")
    print(f"Estatistica W: {stat:.2f}, p-valor: {p_val:.4e}")
    print(f"Tamanho do Efeito (Rank-biserial r): {r_rb:.4f}")
    return {"stat": stat, "p_value": p_val, "r_rb": r_rb}

```

```python
# ============================================================================
# TESTE B: Mann-Whitney U (Nao-pareado: 800 reais x 1200 sinteticas)
# ============================================================================
def run_experiment_b(area_bias_real, area_bias_synth):
    """
    area_bias_real:  Delta Area no teste real (n=800)
    area_bias_synth: Delta Area nas sinteticas (m=1200)
    """
    area_bias_real = np.asarray(area_bias_real)
    area_bias_synth = np.asarray(area_bias_synth)

    # Mann-Whitney bilateral
    u_stat, p_val = stats.mannwhitneyu(area_bias_real, area_bias_synth,
                                       alternative='two-sided')

    n_real = len(area_bias_real)
    m_synth = len(area_bias_synth)

    cles = u_stat / (n_real * m_synth)
    r_rb = 1.0 - (2.0 * u_stat) / (n_real * m_synth)

    print("\n=== TESTE B (Mann-Whitney U - Vies de Area) ===")
    print(f"Mediana Vies Real (n={n_real}): {np.median(area_bias_real):+.4f}")
    print(f"Mediana Vies Sintetico (m={m_synth}): {np.median(area_bias_synth)
    :+.4f}")
    print(f"Estatistica U: {u_stat:.2f}, p-valor: {p_val:.4e}")
    print(f"CLES: {cles:.4f}")
    print(f"Rank-biserial r: {r_rb:.4f}")
    return {"u_stat": u_stat, "p_value": p_val, "cles": cles, "r_rb": r_rb}
```

Listing 1: Script de automação dos experimentos estatísticos.

6 Diretrizes para Redação no IEEE Access

1. **Estatísticas Descritivas Robustas**: Como as distribuições de IoU e área em segmentação sísmica frequentemente violam normalidade, deve-se sempre reportar a *Mediana* e o *Intervalo Interquartil* (IQR), e não apenas média e desvio-padrão.

2. **Tamanho de Efeito**: Em consonância com as boas práticas editoriais do IEEE, nunca baseie a conclusão unicamente no p-valor. O relato do tamanho de efeito (correlação bisserial r e CLES) é indispensável para demonstrar a relevância prática do enriquecimento com imagens sintéticas.

3. **Visualização Gráfica**:

   - Para o Teste A: Recomenda-se um gráfico de dispersão com linha de identidade ($y = x$) ou *Raincloud plot* pareado para explicitar o ganho por imagem.
   - Para o Teste B: Recomenda-se a Curva Cumulativa Empírica (ECDF) ou Boxplot comparativo de $\Delta\text{Area}_{\text{real}}$ vs. $\Delta\text{Area}_{\text{synth}}$.